MTC
WEB
SERVICES

Домашнее задание №2

Дистилляция и ускорение моделей

ИПИИ НИУ ВШЭ

Привет! 👋

Во второй домашней работе ты переходишь от аналитики к инженерной реализации. Если в ДЗ №1 ты анализировал архитектуру и формулировал гипотезы ускорения, то теперь задача — реально применить метод ускорения и экспериментально проверить его эффективность.

Цель работы — показать, что ты умеешь:

- выбрать адекватный метод ускорения под конкретную архитектуру и bottlenecks;
- корректно реализовать его;
- спроектировать эксперимент;
- сравнить модель до и после модификации;
- сделать инженерно обоснованный вывод.

Работа выполняется индивидуально. Срок сдачи — **до 19 февраля.**

Что нужно сделать

1. Выбор базовой модели

Возьми модель, которую ты анализировал в ДЗ №1, и кратко опиши её текущую конфигурацию. Зафиксируй задачу, которую она решает, сценарий использования (training или inference), а также целевую аппаратную платформу. Укажи ключевые bottlenecks, выявленные ранее, поскольку именно они должны стать основанием для выбора метода ускорения.

2. Выбор и реализация метода ускорения

Выбери не менее одного метода ускорения модели — knowledge distillation, quantization или pruning — и реализуй его на выбранной архитектуре. Опиши, почему этот метод подходит именно для данной модели и какие части архитектуры он затрагивает. Поясни, за счёт каких механизмов достигается ускорение:

уменьшение числа параметров, снижение precision, сокращение FLOPs, уменьшение задержки или потребления памяти. Отдельно опиши возможные ограничения метода и риски снижения качества.

3. Алгоритм применения метода
Напиши код на Python для реализации одного или нескольких выбранных методов и сопроводи его подробными комментариями, описывающими шаги алгоритма. Зафиксируй используемые гиперпараметры, особенности настройки и режим применения (например, post-training quantization или quantization-aware training, структура teacher–student при дистилляции, уровень sparsity при pruning). Важно показать, что метод применён осознанно, а не формально.

4. Проведение эксперимента
Проведи эксперимент или серию экспериментов, позволяющих сравнить базовую и ускоренную модель. Опиши конфигурацию среды, параметры запуска и данные, на которых проводились измерения. Эксперимент должен быть воспроизводимым и корректно сопоставлять модели в одинаковых условиях.

5.Выбор и обоснование метрик
Определи метрики качества и производительности, которые будут использоваться для оценки результатов. Поясни, почему именно эти метрики релевантны для выбранной задачи и сценария применения. Необходимо оценивать как качество модели, так и показатели скорости, задержки, памяти или размера модели, если это критично для выбранного сценария.

6. Сравнение модели до и после ускорения
Представь результаты сравнения базовой и модифицированной модели. Зафиксируй изменения в качестве, скорости работы, использовании памяти и размере модели. Важно не просто показать численные значения, а интерпретировать их с инженерной точки зрения.

7. Вывод о целесообразности подхода
Сформулируй вывод о том, насколько оправдан выбранный метод ускорения. Опиши достигнутые выигрыши и компромиссы между качеством и производительностью. Укажи, в каких условиях этот подход целесообразен для production-сценариев, а в каких его применение может быть неэффективным.

Результаты работы

В репозиторий необходимо загрузить:

- отчет (PDF / Markdown / Notebook);
- код реализации;
- таблицы с результатами;

- описание эксперимента;
- ссылки на источники (если использовались).

Также необходимо заполнить и отправить форму ДЗ.

Критерии оценивания

Критерий	**Баллы**	**Что нужно для максимума**	**Типовые ошибки**
1. Корректность выбора метода	0–2	Метод логично связан с архитектурой и bottlenecks	Формальный выбор без связи с моделью
2. Реализация	0–2	Метод реализован корректно, описаны гиперпараметры	Теоретическое описание без кода
3. Дизайн эксперимента	0–2	Эксперимент воспроизводим, корректные сравнения	Нет baseline или некорректные замеры
4. Анализ метрик	0–2	Метрики обоснованы и интерпретированы	Просто таблица без анализа
5. Инженерный вывод	0–2	Чётко описаны trade-offs и применимость	Общие выводы без конкретики

Итого: 10 баллов