

M W

Домашнее задание №3

Дистилляция и ускорение моделей

ИПИИ НИУ ВШЭ

MTC
WEB
SERVICES

S

Привет! 🖐️

В третьей домашней работе ты переходишь от применения отдельного метода ускорения к системному проектированию. Если в ДЗ №2 ты реализовывал конкретный метод и проверял его эффективность, то теперь задача — спроектировать комплексную стратегию ускорения модели под заданные инженерные ограничения.

Это уже не локальный эксперимент, а архитектурное решение уровня production.

Цель работы — показать, что ты умеешь:

- работать с жёсткими ограничениями (latency, память, качество);
- проектировать стратегию ускорения как систему, а не набор приёмов;
- комбинировать методы при необходимости;
- принимать инженерные компромиссы;
- аргументировать решения с точки зрения production-применимости.

Работа выполняется индивидуально.

Срок сдачи — **до 5 марта**

Что нужно сделать

1. Формализовать ограничения.

Необходимо явно задать ограничения, в рамках которых будет проектироваться стратегия: например, задержка $\leq X$ мс, память $\leq Y$ ГБ, допустимая потеря качества $\leq Z$ %, ограничения по размеру модели и целевой платформе. Если ограничения не заданы, их нужно сформулировать самостоятельно как реалистичный production-сценарий. Все ограничения должны быть измеримыми.

2. Зафиксировать baseline.

Кратко опиши исходную модель: архитектуру, текущие метрики качества, задержку,

потребление памяти и размер. Укажи bottlenecks. Это точка отсчёта для всей дальнейшей стратегии.

3. Спроектировать стратегию ускорения.

Необходимо разработать комплексную стратегию ускорения под заданные ограничения. При необходимости допускается комбинирование нескольких методов. Важно показать логику выбора решений, последовательность их применения и ожидаемый вклад каждого шага. Это должна быть именно стратегия, а не перечисление техник. Для каждого выбранного метода нужно обосновать, какую проблему он решает, какой эффект ожидается и какие возможны риски.

4. Описать план реализации.

Опиши, как стратегия будет внедряться: порядок применения методов, ключевые гиперпараметры, структура экспериментов и критерии остановки. Формат работы может быть полностью экспериментальным с демонстрацией на целевой платформе либо частично экспериментальным и частично аналитическим

5. Провести сравнение и представить результаты.

Если выполняется практическая часть, необходимо провести корректные сравнительные эксперименты и зафиксировать результаты в виде таблиц или графиков. Нужно сравнить baseline и итоговую модель по качеству, задержке, памяти и размеру. Важно не просто показать цифры, а интерпретировать их и соотнести с исходными ограничениями.

6. Сделать инженерный вывод.

Сформулируй вывод о том, достигнуты ли заданные ограничения, какие компромиссы были приняты и насколько стратегия применима в production. Отдельно укажи, в каких условиях такой подход оправдан, а в каких может быть избыточным.

Формат сдачи

Результаты необходимо оформить в виде отчёта или презентации, включив перечень ограничений, выбранную стратегию, результаты экспериментов и инженерные выводы. Материалы загружаются в репозиторий, также необходимо заполнить и отправить форму ДЗ.

Критерии оценивания

Критерий	Баллы	Что нужно для максимума	Типовые ошибки
1. Корректность постановки ограничений	0–2	Ограничения чётко заданы и измеримы	Абстрактные формулировки
2. Архитектурное проектирование стратегии	0–2	Есть логика комбинирования методов	Просто перечисление техник

3. Реализация / аналитическая проработка	0–2	Корректные эксперименты или расчёты	Отсутствие доказательств
4. Анализ результатов	0–2	Глубокая инженерная интерпретация	Таблицы без анализа
5. Инженерный вывод	0–2	Чёткие trade-offs и production-позиция	Общие выводы

Итого: 10 баллов